

Fundamentos de Aprendizagem de Máquina

Hélio Pio

Programação das Aulas

Tópico 1: Introdução a Inteligência Artificial

Tópico 2: Agentes Inteligentes

Tópico 3: Fundamentos de Aprendizagem de Máquina

Tópico 4: Redes Neurais Artificiais

Tópico 5: Atividade em Aula – Primeira Avaliação

Tópico 6: Representação da Incerteza e Lógica Fuzzy

Tópico 7: Redes Bayesianas

Tópico 8: Support Vector Machines

Tópico 9: Atividade em Aula – Segunda Avaliação

Tópico 10: Resolução de Problemas por Meio de Busca e Otimização


Tópico 11: Técnicas de Ensemble

Tópico 12: Atividade em Aula – Terceira Avaliação

O que é lógica *Fuzzy*?

Lógica *Fuzzy*

O que é lógica *Fuzzy*?



Lógica *Fuzzy*


O que é lógica *Fuzzy*?

- Este copo está cheio ou vazio?
- Ou está meio vazio, ou meio cheio?



Lógica *Fuzzy*

O que é lógica *Fuzzy*?




Lógica Booleana



Lógica *Fuzzy*

O que é lógica *Fuzzy*?



Lógica *Fuzzy*



Lógica *Fuzzy*

O que é lógica *Fuzzy*?

- Lógica *Fuzzy* é uma extensão da lógica booleana, que permite lidar com informações imprecisas ou incertas.
- Ela permite que variáveis possuam valores parcialmente verdadeiros ou falsos, em vez de serem restritas a valores binários. Isso é alcançado através do uso de funções de pertinência, que atribuem graus de pertinência a um conjunto de valores.
- A Lógica *Fuzzy* é usada em sistemas de controle, tomada de decisões, reconhecimento de padrões e outras aplicações em que a precisão não é essencial e a incerteza é comum.

Lógica Fuzzy

Introdução

- Na vida prática 99% dos problemas são:
 - Complexos demais para a aplicação de modelos convencionais ou “clássicos”.
 - Definidos de maneira vaga, imprecisa, incerta.
- Definições “qualitativas” normalmente não impedem que se chegue a resultados “quantitativos”.
- O que significa:
 - Estacionar perto da calçada!
 - Uma colher de sopa de açúcar!



Lógica *Fuzzy*

Introdução

- A lógica nebulosa propõe uma ontologia que permite que um evento seja definido de forma vaga – um grau de verdade.
 - Um evento pode ser/ter “uma certa verdade”.
 - É uma forma de especificar quão bem um objeto satisfaz uma descrição vaga.
- Lógica Nebulosa e Conjuntos Nebulosos permitem a representação de tal “vagueza”.



Lógica Fuzzy

Teoria da Probabilidade vs Lógica Nebulosa

- Probabilidade - Grau de crença (*belief*)
 - Ex.: 80% - 'A' é verdade 8 vezes e falso 2 vezes, em dez casos .
 - Fatos (A) são verdadeiros ou falsos.
- Lógica nebulosa - Grau de verdade (*truth*)
 - Ex.: “João é alto.” Isso é verdade ou falso, sabendo que João mede 1,75m de altura?
 - Não há incerteza no mundo exterior (sabe-se a altura de João), há incerteza no significado linguístico de “alto”.



Lógica *Fuzzy*

Teoria Clássica de Conjuntos vs Conjuntos Nebulosos

- Conjunto: é definido por um predicado da lógica clássica que caracteriza os elementos que pertencem ao conjunto.
 - Função característica $\eta_A: U \rightarrow \{0,1\}$
 - ✓ U : Universo de discurso
 - ✓ η : associa a cada elemento $a \in U$, $A \subset U$, um valor binário (1 se $a \in A$, 0 se $a \notin A$ – define um conjunto)
- Conjunto nebuloso: extensão para tratar graus de pertinência intermediários.
 - Função de pertinência $\mu_A: U \rightarrow [0,1]$
 - ✓ μ : associa a cada elemento $a \in U$, $A \subset U$, um valor do intervalo real fechado $[0,1]$, com 1 se $a \in A$, 0 se $a \notin A$ e outros valores para pertinências intermediárias.

Lógica *Fuzzy*

Teoria Clássica de Conjuntos vs Conjuntos Nebulosos

- $\mu_A(a)$ = grau de pertinência de a ao conjunto nebuloso A :
 - É uma medida da força com que um elemento pertence a um conjunto nebuloso.
 - Quanto maior o grau de pertinência:
 - Maior a confiança de que o evento ocorrerá.
 - Maior o grau de certeza de uma afirmativa.
 - Maior a possibilidade de ocorrência de um evento.
 - Maior a propensão em acreditar em uma asserção.



Lógica *Fuzzy*

Conjuntos Nebulosos: Ideia Central

- Existe no mundo situações onde os limites entre conjuntos não são claramente definidos:
 - Não são *crisp* (nítidos)
 - São *fuzzy* (nebulosos)
 - ✓ Ex: *crisp*: estado de um bit, sinal de trânsito etc;
fuzzy: velho x novo, quente x frio, etc.
- Lógica Nebulosa (ou Teoria de Conjuntos Nebulosos) é uma tentativa de tratar conceitos vagos, não incerteza! **Vago ≠ incerto!**


Lógica *Fuzzy*

Incerto e vago

- Modelo Clássico
 - Se Temperatura = 100°C, ENTÃO Velocidade = 5 Km/h
- Modelo Impreciso
 - Se Temperatura \geq 100°C, ENTÃO Velocidade \leq 5 Km/h
- Modelo Incerto
 - Se Temperatura \geq 100°C, ENTÃO $P(\text{Velocidade}=5 \text{ Km/h}) = 0,7$
- Modelo Vago
 - Se Temperatura = ALTA, ENTÃO Velocidade = BAIXA

Lógica *Fuzzy*


Conjuntos Clásicos vs Conjuntos Nebulosos



Lógica Fuzzy

Exemplos de aplicações

- Metrô de Sendai – Japão (controle de velocidade).
- Câmera Reflex Sanyo (mecanismo de foco).
- Ducha Eletrônica Panasonic (controle de temperatura).
- Máquinas de Lavar Roupa.
- Freio ABS.



Lógica Fuzzy

Operações nebulosas básicas (Zadeh, 1965)

- x : valor da variável linguística.
- A, B : conjuntos nebulosos (termos primários da variável linguística)

Complemento: $\mu_{\neg A}(x_i) = 1 - \mu_A(x_i)$

União: $\mu_{A \cup B} = \max[\mu_A(x_i), \mu_B(x_i)]$

Interseção: $\mu_{A \cap B} = \min[\mu_A(x_i), \mu_B(x_i)]$

– União \rightarrow conectivo lógico OU

– Interseção \rightarrow conectivo lógico E

Lógica Fuzzy

Representação nebulosa do conhecimento

- Variável linguística
 - Representa um conceito ou variável de um problema
 - Seus termos primários podem ser representados por conjuntos nebulosos.
 - Termos primários formam a partição nebulosa da variável.

Variável linguística :

– Idade


Termos primários :

– Jovem

– Velho

Universo de discurso :

– 0 – 100 anos



Lógica Fuzzy

Representação nebulosa do conhecimento

- Base de Conhecimento: regras de produção
 - Se <antecedente> então <consequente>
 - ✓ Antecedente: conjunto de condições
 - ✓ Consequente: ações
- Os consequentes das regras disparadas são processados em conjunto para gerar uma resposta determinística para cada variável de saída do sistema.

Exemplo:

Velocidade [0,220]

Baixa, Média e alta

1. Se velocidade > 100
Então DPP é 30 metros
2. Se velocidade < 40
Então DPP é 10 metros

1. Se velocidade é alta
Então DPP é longa
2. Se velocidade é baixa
Então DPP é curta

Lógica *Fuzzy*

Modelo de inferência nebulosa

- Mais simples do que os mecanismos clássicos:
 - Existe apenas *forward chaining*.
 - Não se faz o *matching* do consequente de uma regra com os antecedentes de outra.
 - Somente existem inferências diretas de um único nível.
 - Todas as regras são disparadas.

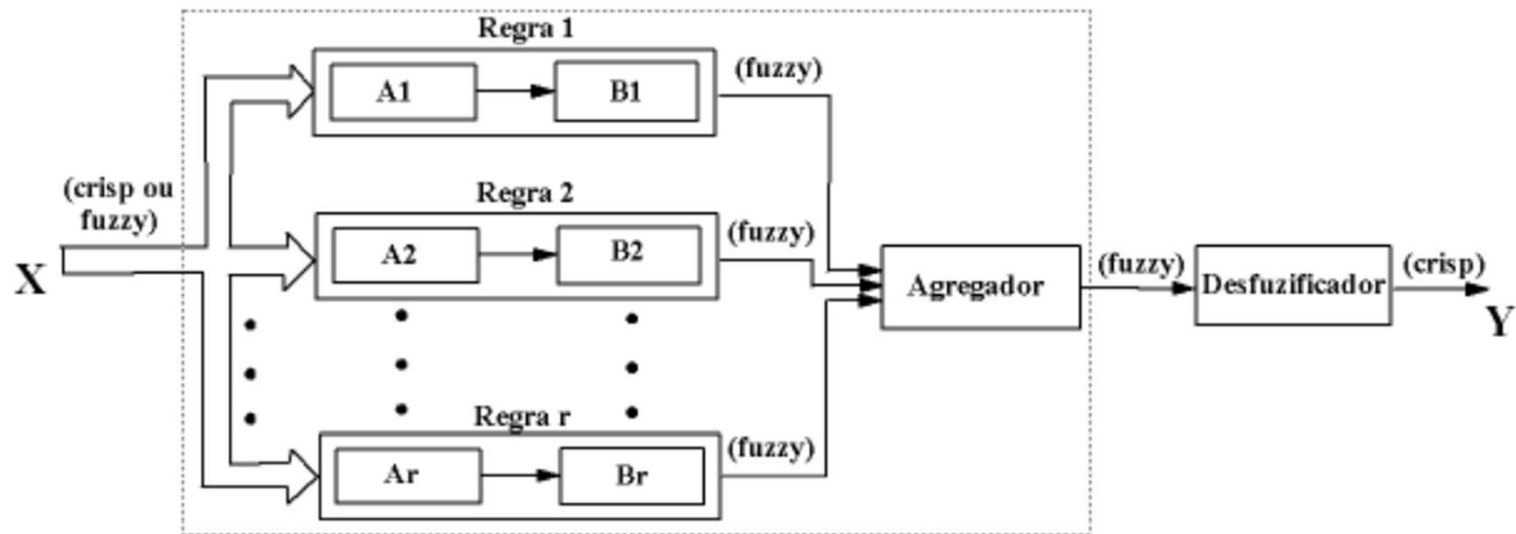
Lógica *Fuzzy*

Projeto de um sistema nebuloso

- Passo 1: Definição do universo de discurso das variáveis de entrada e de saída.
- Passo 2: Partição dos universos de discurso definidos.
 - Criação dos termos primários e graus de pertinência.
- Passo 3: Definição das regras que compõem a base de conhecimento.
- Passo 4: Definição da técnica de *defuzzyficação*
 - Centro de gravidade, média dos máximos, valor máximo, etc.

Lógica Fuzzy

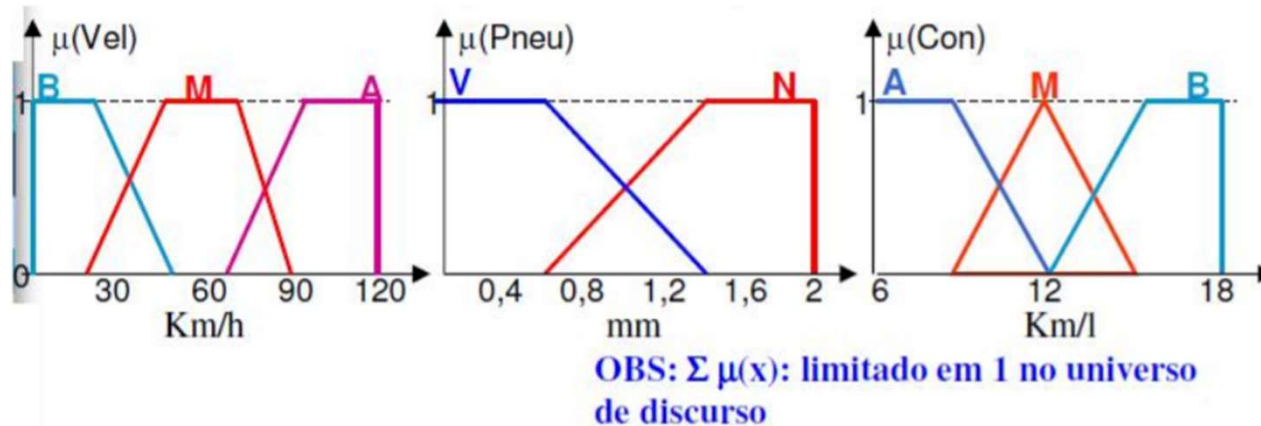
Modelo de inferência nebulosa



Lógica Fuzzy

Exercício 1: Consumo de combustível de um automóvel.

- Passo (1): Definição do universo de discurso das variáveis de entrada e de saída
 - Variáveis de entrada: velocidade (Vel), pneu (Pneu)
 - Variável de saída: consumo (Con)
- Passo (2): Partição dos universos de discurso definidos
 - Vel = [Baixa, Média, Alta]; Pneu = [Velho, Novo]
 - Con = [Baixo, Médio, Alto]



Lógica Fuzzy

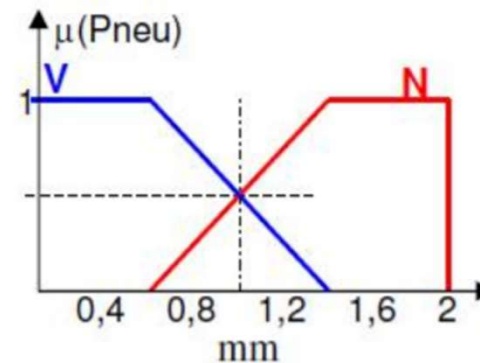

Exercício 1: Consumo de combustível de um automóvel.

- Passo (3): Definição das regras que compõem a base de conhecimento
 - Regra 1: Se Vel = B e Pneu = V, então Con = A.
 - Regra 2: Se Vel = B e Pneu = N, então Con = M.
 - Regra 3: Se Vel = M e Pneu = V, então Con = M.
 - Regra 4: Se Vel = M e Pneu = N, então Con = B.
 - Regra 5: Se Vel = A e Pneu = V, então Con = A.
 - Regra 6: Se Vel = A e Pneu = N, então Con = M
- Passo (4): Definição da técnica de defuzzyficação
 - Adotar centro de área.

Lógica Fuzzy

Exercício 1: Consumo de combustível de um automóvel.

- Dados Vel = 35 km/h; Pneu = 1mm. Qual o valor do consumo Con = ?
- Fuzzificação:
 - Vel: $\mu_B(35) = 0,75$, $\mu_M(35) = 0,25$, $\mu_A(35) = 0,0$
 - Pneu: $\mu_V(1) = 0,5$, $\mu_N(1) = 0,5$



Lógica Fuzzy

Exercício 1: Consumo de combustível de um automóvel.

- Regra semântica: máx – min

1. Antecedentes: Interseção nebulosa entre os graus de pertinência das entradas atuais nos termos primários → coeficiente de disparo D_k para cada regra k .

$$D^k = \min [\mu_{A1k}(X_1), \mu_{A2k}(X_2), \dots, \mu_{Apk}(X_p)]$$

2. Todas as regras com $D_k > 0$, disparam.

3. Consequentes: limitados pelo coeficiente de disparo nos seus valores máximos dos conjuntos de saída.

4. Operação global de união compõe um conjunto nebuloso para cada variável de saída (informações de todas as regras).

$$\mu_{B^i}(y) = \max [\min(D^k, \mu_{Bi}(y))], \forall y \in U_{y^i}$$

Lógica Fuzzy

Exercício 1: Apoio à decisão



- Inferência
 - $D1 = \min[\mu_b(35), \mu_v(1)] = 0,5$ (Con – A)

$$\mu_b(35) = 0,75$$

$$\mu_v(1) = 0,5$$

$$\min[0,75; 0,5] = 0,5$$

Vel (Baixa) e Pneu (Velho) \Rightarrow Con (Alto)



Lógica Fuzzy

Exercício 1: Apoio à decisão



- Inferência
 - $D1 = \min[\mu_b(35), \mu_v(1)] = 0,5$ (Con – A)
 - $D2 = \min[\mu_b(35), \mu_n(1)] = 0,5$ (Con – M)

$$\mu_b(35) = 0,75$$

$$\mu_n(1) = 0,5$$

$$\min[0,75; 0,5] = 0,5$$



Vel (Baixa) e Pneu (Novo) \Rightarrow Con (Médio)



Lógica Fuzzy

Exercício 1: Apoio à decisão


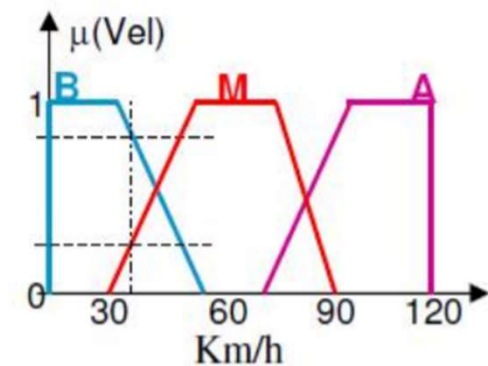
- Inferência
 - $D1 = \min[\mu_b(35), \mu_v(1)] = 0,5$ (Con – A)
 - $D2 = \min[\mu_b(35), \mu_n(1)] = 0,5$ (Con – M)
 - $D3 = \min[\mu_m(35), \mu_v(1)] = 0,25$ (Con – M)
 - $D4 = \min[\mu_m(35), \mu_n(1)] = 0,25$ (Con – B)
 - $D5 = \min[\mu_a(35), \mu_v(1)] = 0,0$ (Con – A)
 - $D6 = \min[\mu_a(35), \mu_n(1)] = 0,0$ (Con – M)



Lógica Fuzzy

Exercício 1: Apoio à decisão



- Inferência
 - $D1 = \min[\mu_b(35), \mu_v(1)] = 0,5$ (Con – A)
 - $D2 = \min[\mu_b(35), \mu_n(1)] = 0,5$ (Con – M)
 - $D3 = \min[\mu_m(35), \mu_v(1)] = 0,25$ (Con – M)
 - $D4 = \min[\mu_m(35), \mu_n(1)] = 0,25$ (Con – B)
 - $D5 = \min[\mu_a(35), \mu_v(1)] = 0,0$ (Con – A)
 - $D6 = \min[\mu_a(35), \mu_n(1)] = 0,0$ (Con – M)
 - A: $\max(0,5; 0) = 0,5$



Lógica Fuzzy

Exercício 1: Apoio à decisão

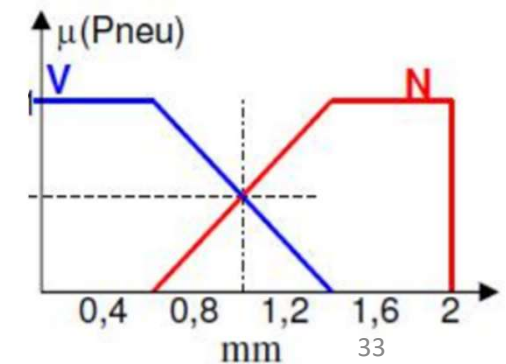


- Inferência
 - $D1 = \min[\mu_b(35), \mu_v(1)] = 0,5$ (Con – A)
 - $D2 = \min[\mu_b(35), \mu_n(1)] = 0,5$ (Con – M)
 - $D3 = \min[\mu_m(35), \mu_v(1)] = 0,25$ (Con – M)
 - $D4 = \min[\mu_m(35), \mu_n(1)] = 0,25$ (Con – B)
 - $D5 = \min[\mu_a(35), \mu_v(1)] = 0,0$ (Con – A)
 - $D6 = \min[\mu_a(35), \mu_n(1)] = 0,0$ (Con – M)
 - A: $\max(0,5; 0) = 0,5$
 - M: $\max(0,5; 0,25; 0) = 0,5$
 - B: $\max(0,25) = 0,25$



Lógica Fuzzy

Exercício 1: Apoio à decisão

- Inferência
 - $D1 = \min[\mu_b(35), \mu_v(1)] = 0,5$ (Con – A)
 - $D2 = \min[\mu_b(35), \mu_n(1)] = 0,5$ (Con – M)
 - $D3 = \min[\mu_m(35), \mu_v(1)] = 0,25$ (Con – M)
 - $D4 = \min[\mu_m(35), \mu_n(1)] = 0,25$ (Con – B)
 - $D5 = \min[\mu_a(35), \mu_v(1)] = 0,0$ (Con – A)
 - $D6 = \min[\mu_a(35), \mu_n(1)] = 0,0$ (Con – M)
 - A: $\max(0,5; 0) = 0,5$
 - M: $\max(0,5; 0,25; 0) = 0,5$
 - B: $\max(0,25) = 0,25$
- Defuzzificação (centro da área):
 - Con = 11,5km/l



Lógica *Fuzzy*

Sistemas *Neuro-Fuzzy*

- Sistemas Neuro-Fuzzy são sistemas híbridos que combinam as técnicas de Redes Neurais Artificiais (RNA) e Lógica Fuzzy. Eles são usados para modelagem e controle de sistemas complexos, onde a lógica fuzzy é usada para lidar com a incerteza e a imprecisão dos dados, enquanto as redes neurais são usadas para aprender padrões e relações entre dados.
- Os sistemas Neuro-Fuzzy possuem uma arquitetura que combina blocos de lógica fuzzy com redes neurais. O bloco de lógica fuzzy é usado para mapear as variáveis de entrada em valores linguísticos, enquanto a rede neural é usada para aprender as relações entre as variáveis de entrada e saída.

Lógica *Fuzzy*

Sistemas *Neuro-Fuzzy*

- Os sistemas Neuro-Fuzzy são usados em diversas aplicações, como controle de processos, sistemas de previsão, diagnóstico médico, entre outros. Eles são capazes de lidar com dados imprecisos e incertos, e têm uma capacidade de aprendizado que permite que se adaptem a diferentes situações. Essas características os tornam uma ferramenta poderosa para a solução de problemas complexos em muitas áreas.

Lógica *Fuzzy*

Sistemas *Neuro-Fuzzy* (Aplicações)

- Controle de processos industriais: Os sistemas *Neuro-Fuzzy* são usados para controlar processos industriais complexos, como a fabricação de produtos químicos, com a capacidade de lidar com dados imprecisos e variáveis de entrada incertas.
- Previsão de vendas: Os sistemas *Neuro-Fuzzy* são usados para prever as vendas futuras com base em dados históricos, levando em consideração fatores como sazonalidade, tendências e eventos imprevisíveis.
- Diagnóstico médico: Os sistemas *Neuro-Fuzzy* são usados para diagnosticar doenças com base em sintomas e dados de pacientes, levando em consideração a incerteza e a imprecisão dos dados.


Lógica *Fuzzy*

Sistemas *Neuro-Fuzzy* (Aplicações)


- Controle de veículos autônomos: Os sistemas Neuro-Fuzzy são usados para controlar veículos autônomos, com a capacidade de lidar com informações imprecisas, como as condições da estrada, o clima e o tráfego.
- Sistemas de recomendação: Os sistemas Neuro-Fuzzy são usados para recomendar produtos ou serviços com base nas preferências do usuário, levando em consideração a incerteza e a imprecisão dos dados.

Lógica Fuzzy


Neurônio Fuzzy




Modelo lógico OU



Modelo lógico E



Neurônio Fuzzy com entrada Crisp



Neurônio Fuzzy com entrada Fuzzy

E agora?

Comentários